

Assistente agêntico do Motor de Relacionamento

Arquitetura de referência e blueprint replicável · Fabricio Espel · setembro de 2026

Resumo executivo

O piloto adiciona ao Motor de Relacionamento uma camada agêntica que atende o cliente no WhatsApp e no app, responde com base no conhecimento oficial do banco e executa transações simples. Por ser o primeiro caso do CoE, nasce como **blueprint**: o que é comum a qualquer área vira plataforma; o que é de domínio vira configuração.

A tese central é "**o LLM interpreta, a regra autoriza**": o modelo entende o cliente e redige respostas; se uma ação pode ser executada, com quais parâmetros e com qual autenticação, quem decide é código determinístico, testável e auditável. Quatro ideias estruturam o documento: **evolução, não substituição** (convivência com o atendimento atual e migração por intenção); **quatro tipos de pedido**, com escalonamento para humano como saída transversal; **defesa em profundidade**; e **quatro encaixes** que a próxima área preenche. Premissas e fontes estão no apêndice.

1. Arquitetura de solução

1.1 Contexto (C4, nível 1)




Diagrama 1: C4 Context.

O escopo é a camada agêntica, dentro do Motor de Relacionamento e ao lado do atendimento atual, que é preservado. O **app tem papel duplo**: canal e fator de autenticação. A **identidade chega pelo provedor de identidade**, nunca pelo texto da conversa. A **plataforma de IA é sistema externo** por ser o único ponto em que dado sai da jurisdição (endpoint global); por isso recebe só texto pseudonimizado, sem dados identificadores nem financeiros.

1.2 Containers (C4, nível 2)

- **Plataforma compartilhada, operada pelo CoE**: gateway de canal, política, guardrails, auditoria, observabilidade. **Templates**: agente e base de conhecimento por área de negócio; servidor MCP por domínio de sistema.
- **Política consultada duas vezes**: pelo agente, para conduzir a conversa, e pelo servidor MCP, que barra na execução. Vale a do executor.
- **Cofre de sessão**: token do cliente e dados pessoais num Firestore em São Paulo, criptografado e com expiração, acessível por IAM só ao gateway e ao servidor MCP. O agente não tem permissão alguma, e a identidade chega ao MCP pelo contexto autenticado da requisição, nunca por parâmetro escolhido pelo LLM.
- **Guardrails em dois pontos**: o mascaramento (Sensitive Data Protection, em São Paulo) acontece no gateway, antes do agente; o Model Armor, sem região no Brasil, atua no agente sobre texto já pseudonimizado.
- **Integrações** só via servidor MCP (pelo gateway de APIs corporativo, com troca de token), gateway de canal ou barramento de eventos. O agente não chama APIs.




Diagrama 2: C4 Container.

1.3 Componentes do agente (C4, nível 3)




Diagrama 3: C4 Component do Agente.

O agente é um **grafo determinístico com LLM dentro dos nós**: o LLM classifica, responde perguntas de conhecimento, esclarece e resume para o atendente; a sequência "autenticar → confirmar → executar" é do grafo e não pode ser pulada. Ferramentas de escrita existem só no subfluxo transacional: um agente de conhecimento manipulado por conteúdo malicioso não pode chamá-las, porque elas não estão no seu contexto.

1.4 Decisões principais

Decisão	Escolha	Alternativa descartada	Por quê
Build vs. buy	Comprar a plataforma (Gemini, Agent Runtime, RAG Engine, Model Armor, provedor de WhatsApp); construir o diferencial (integração transacional, política, guardrails de ação, avaliação)	Suíte de atendimento pronta; construir tudo	O diferencial do banco está nas regras e no controle das ações, não no motor de linguagem. Padrões abertos nas fronteiras (MCP, OpenTelemetry) reduzem o lock-in
Modelo único vs. multimodelo	Gemini Flash por padrão; Gemini Pro só no conhecimento, por critério (várias fontes, falha na verificação, tema regulatório)	Pro para tudo; Flash para tudo	A maioria das mensagens é simples. O critério leva o Pro para onde muda o resultado e é validado na avaliação. Nunca no caminho transacional
Orquestração	ADK no Agent Runtime, com grafo determinístico e LLM nos nós	Agente autônomo com todas as ferramentas; orquestração própria; LangGraph	Autonomia onde agrega valor, previsibilidade onde não pode haver erro. Plataforma gerenciada, alinhada à stack GCP, reduz o custo de replicar

Residência: inferência no endpoint global, com sessões, base e auditoria em São Paulo; em SP há hoje só o Gemini 2.5 Flash. O modelo é parâmetro, e a opção regional fica disponível se Compliance decidir. **RAG** por padrão; GraphRAG

quando um caso exigir relações que a busca perde. **A2A** previsto como evolução.

2. Fluxo agêntico

2.1 Tipos de pedido e a decisão "responder vs. executar"

Tipo	Exemplo	Caminho	Exige
Informação geral	"Qual a anuidade do cartão?"	Busca na base, com citação	Nada
Consulta	"Qual meu limite?"	Ferramenta de leitura	Número vinculado
Transação	"Bloqueia meu cartão"	Política → confirmação → escrita	Autenticação conforme o risco
Fora de escopo	"Qual ação devo comprar?"	Recusa educada	—

A decisão **não é do modelo**: (1) o LLM classifica numa intenção do catálogo; (2) o **catálogo** define tipo, risco, autenticação, limites e fase liberada, e nega o que não conhece; (3) a **política** decide; (4) a política gera a **confirmação amarrada aos parâmetros** (texto fixo, uso único, validade curta), o cliente confirma por botão e o executor só aceita o que bate com ela. O catálogo é configuração versionada, alterada com segregação de funções e publicada assinada; acima dele, um **piso de invariantes do CoE** (toda escrita exige confirmação; intenção nova entra em shadow mode) que nenhuma área sobrescreve.

2.2 Fluxo de referência: bloqueio de cartão

É o caminho mais completo; os demais tipos são recortes dele.




Diagrama 4: diagrama dinâmico do bloqueio. 23h10, número vinculado: "perdi minha carteira, bloqueia meu cartão urgente".

1. **Gateway** valida, deduplica, identifica o número, mascara e roteia. *Sem LLM.*
2. **Classificador** identifica `bloqueio_temporario_cartao`. **Única chamada ao LLM.**
3. **Ferramenta de leitura** lista os cartões para o subfluxo (código), que pergunta qual com botões. *Sem LLM: dados do cartão não passam pelo modelo.*
4. **Política** aprova com confirmação; o cliente toca em "Sim, bloquear". *Sem LLM.*
5. **Servidor MCP** executa em nome do cliente, com idempotência. *Sem LLM.*
6. **Evento** para antifraude, CRM e notificação por outro canal. *Sem LLM.*
7. **Resposta** em texto fixo, reforçando que o desbloqueio é só no app; tudo vai à **auditoria**. *Sem LLM.*

Falhas: na ambiguidade, pergunta direcionada com botões e, após duas tentativas, escalonamento; o limite de confiança é maior para transações e calibrado na avaliação. Erro de classificação nunca vira ação: a confirmação é a última barreira. Sem resposta do sistema, **nunca afirma sucesso**: consulta o estado, abre protocolo, informa o canal 24h e reconcilia depois.

2.3 Fluxo de referência: pergunta de conhecimento

"Qual a anuidade do Gold?" (nível 0): **classificação (LLM)** → **cache semântico** para perguntas repetidas, com mesma intenção e entidades e documentos vigentes; consulta e transação nunca são cacheadas (*sem LLM*) → **busca** em documentos vigentes e com dono, com valores vindos da **tabela oficial (sem LLM)** → **resposta** com citação por afirmação (*LLM; Pro se o critério acionar*) → **verificação de fundamentação**; se falhar duas vezes, recusa e oferece humano (*LLM*) → **Model Armor** e envio. Até três chamadas por turno: é o fluxo de maior risco e maior custo.

2.4 Autenticação progressiva

O número do WhatsApp **identifica, mas não autentica**. Segue o padrão do mercado brasileiro: vínculo pelo app, autorização separada para transacionar, fator por operação, limites por canal.

Nível	Como se obtém	Libera
0	—	Informação geral
1	Número vinculado	Consultas
2	Autorização no app + sessão curta	Transações de baixo risco
3	Biometria no app para a operação	Transações de risco médio

A exigência segue o **risco da ação**: o bloqueio temporário, reversível, exige nível 1 e confirmação; o desbloqueio, nível 3 e só no app, o que fecha o caminho do golpe da falsa central.

2.5 Memória e escalonamento

Curto prazo é a sessão. Longo prazo, só preferências de interação, com consentimento; **fatos transacionais ficam nos sistemas de registro e no CRM**, consultados por ferramenta (evita dado desatualizado e envenenamento de memória). Escala para humano por pedido, negativa da política, falta de fonte, falhas repetidas, tema sensível ou frustração, com resumo; fora do horário, protocolo e canal 24h para urgências.

3. Guardrails, segurança e compliance

3.1 Ameaças e controles

Ameaça	Controles (camadas)
Alucinação	Resposta só com trechos recuperados · citação · verificação de fundamentação · valores de fonte estruturada · recusa sem fonte
Prompt injection	Model Armor (entrada, conteúdo recuperado, saída) · escrita fora do contexto do LLM · política · confirmação amarrada · identidade pelo canal
Vazamento	Dados identificadores e financeiros fora do LLM (3.2) · ferramentas limitadas ao cliente autenticado
Ações indevidas	Negação por padrão · autenticação por risco · limites · política no executor · idempotência · antifraude
Adulteração da configuração	Catálogo versionado, assinado, somente leitura em produção · alerta a cada versão · piso do CoE
Abuso e custo	Limite de mensagens por cliente · teto de turnos e contexto · alertas de custo
Base envenenada	Fontes aprovadas e com dono · triagem de documentos · versionamento

O Model Armor reduz o volume de ataques; a garantia vem das camadas determinísticas.

3.2 Dados do cliente fora do modelo

O LLM redige; quem preenche os valores do cliente é código. Identidade: o modelo não recebe CPF, nome ou conta. O que o cliente digita: marcadores reversíveis ([CPF_1]), com o valor no cofre; número de cartão é descartado, o que mantém a camada fora do escopo do PCI DSS. O que as ferramentas retornam: mensagens transacionais são modelos fixos; consultas usam placeholders ({limite_disponivel}) preenchidos no envio. **O limite**: o texto da conversa chega pseudonimizado, e dado pseudonimizado continua pessoal pela LGPD. O risco cai, mas não zera; por isso a decisão de transferência é de Compliance/DPO.

3.3 LGPD e setor financeiro

- **LGPD**: minimização (art. 6) · exclusão e acesso (art. 18) · **toda negativa automática oferece humano (art. 20)** · transferência restrita a texto pseudonimizado (art. 33) · base para registro de tratamento e relatório de impacto (arts. 37–38) · transparência.
- **Auditoria**: intenção, versão do catálogo, regra, confirmação, hash dos parâmetros, resultado e versões, sem identificadores em claro; imutável, acesso restrito, retenção definida por Jurídico e Compliance.
- **Nuvem e modelos**: governança de nuvem do banco (Res. CMN 4.893/2021); mudanças versionadas, modelo com versão fixada, gate de avaliação, aprovação proporcional ao risco, agente no inventário de modelos.

4. Avaliação e observabilidade

Offline (gate): golden set, red team e regressão, em quatro níveis (recuperação, ingestão, resposta final, contínuo), porque recuperação perfeita não garante resposta certa. Métricas por componente (classificador, roteamento, trajetória); **zero ataques com escrita ou vazamento**; falso positivo de guardrail também é defeito. Juiz LLM calibrado contra rótulos humanos, com modelo diferente do avaliado. Limites definidos antes; são os critérios de promoção da seção 7.

Online: qualidade (juiz em amostra, falhas de fundamentação), segurança (ataques, bloqueios) e resultado para o cliente, com **recontato em 24–72h** para não inflar a taxa de resolução.

Observabilidade: um trace por turno em **OpenTelemetry**, com um span por passo; um coletor distribui para Cloud Trace, **Dynatrace** (OTLP) e Langfuse opcional. Trace, auditoria e conversa se correlacionam. Dos traces saem latência p50/p95 e custo por conversa. Drift: distribuição de intenções, perguntas sem resposta (backlog de conteúdo), qualidade e custo (detalhe no apêndice).

5. FinOps e escalabilidade

5.1 Estimativa para 50 mil conversas por mês

Premissas estimadas, a medir no shadow mode (apêndice A). Por conversa, o modelo custa US\$ 0,042 no conhecimento e US\$ 0,010–0,013 nos demais tipos: **conhecimento custa quatro vezes uma transação**.

Por mês	2026 (preço promocional)	2027+ (preço padrão)
Modelos	~US\$ 1.350	~US\$ 2.600
Demais itens (guardrails, banco vetorial, runtime, serviços, avaliações)	~US\$ 750	~US\$ 750
Plataforma	~US\$ 2.100 (~US\$ 0,04/conversa)	~US\$ 3.300 (~US\$ 0,07/conversa)
WhatsApp (Meta), iniciado pelo cliente	US\$ 0	US\$ 0
Provedor de WhatsApp, se cobrar por mensagem	US\$ 1.350–4.500	US\$ 1.350–4.500

Fontes públicas de Google Cloud e Meta (26/set/2026); fora da conta ficam licenças já existentes e pessoas. Três leituras: **o custo de modelo dobra em 2027**; **o provedor de WhatsApp pode custar mais que toda a IA**, o que torna a integração direta uma decisão financeira; e o custo por conversa deve ser comparado ao do atendimento atual.

5.2 Sensibilidade e alavancas

O mix é a premissa mais incerta, mas não a que mais pesa: se conhecimento subir de 50% para 60%, o custo de modelo sobe ~11%; com 100%, 56% (~US\$ 2.100/mês), sem mudar a ordem de grandeza. Pesam mais o fim do preço promocional (+92%) e um turno a mais nas conversas de conhecimento (+26%). **Nenhum orçamento de escala é comprometido antes de o shadow medir o mix e os turnos reais.**

Alavancas: integração direta com a Meta; **cache semântico** de informação geral (~30% do custo de conhecimento); cache de contexto (~20%); Flash-Lite no classificador, se aprovado na avaliação; limite de raciocínio e de turnos; avaliações em lote. Juntas, reduzem o custo de modelo em 40–50%.

5.3 Escala para milhões

Com 2 milhões de conversas/mês, o modelo iria a ~US\$ 54–104 mil sem otimização. A arquitetura escala com **fila** entre webhook e agente (picos de vencimento e datas do varejo), **capacidade reservada** de modelo com cotas, **roteador como válvula** (baixa o canário e devolve tráfego ao atendimento atual), **amostragem de traces** e **showback** de custo por área e intenção.

6. Reusabilidade e papel do CoE

Aceleradores: o que precisa ser igual para todos é serviço; o que muda por domínio é template. **Agentes por área de negócio, servidores MCP por domínio de sistema, plataforma compartilhada no centro** (catálogo completo no apêndice). A próxima área preenche quatro encaixes: **catálogo de intenções, ferramentas** (reutilizando os MCP existentes), **base de conhecimento e conjunto de avaliação**. Com as integrações disponíveis, chega ao shadow em cerca de seis semanas; o gargalo passa a ser APIs legadas e conteúdo. O blueprint elimina o trabalho repetido, não o novo.

Modelo de operação:

- **Entrada única, quatro trilhas:** autoatendimento, caminho pronto, co-construção (vira acelerador) e "não é IA". Recusar bem também é papel do CoE.
- **Carteira:** maior parte da capacidade no caminho pronto, fatia fixa para apostas estruturantes (ex.: GraphRAG), fatia pequena para exploração; valor × viabilidade × reuso, com limite de iniciativas por arquiteto e fila visível.
- **Níveis de envolvimento:** o CoE faz → faz com a área → a área faz e o CoE revisa → a área é autônoma. O objetivo é mover as áreas para a direita.
- **Governança como código** e, contra o Shadow AI, **caminho oficial mais fácil**; ADRs, trilhas por papel e comunidade. Métricas: tempo até o shadow, reuso, maturidade das áreas, custo por área, incidentes.

7. Roadmap e riscos

7.1 Fases

Promoção **por intenção**, critérios definidos antes e que valem de verdade, regressão automática em violação de segurança. Segurança é critério absoluto; qualidade é relativa ao atendimento atual.

Fase	O que acontece	Para avançar
0. Fundação	Discovery, integrações, base com donos, avaliação, relatório de impacto	Gate aprovado · red team sem escrita nem vazamento
1. Shadow	Amostra de 10–20% das conversas processada sem responder, executar ou consultar dados do cliente	Qualidade em amostra rotulada · zero incidentes · mix e custo medidos, orçamento aprovado
2. Assistido	Agente redige, atendente aprova	Aceitação sem edição ≥ 80%
3. Autônomo: conhecimento e consulta	Canário 5% → 25% → 100% por intenção	Recontato e CSAT não piores · fundamentação ≥ 95% · kill switch testado
4. Autônomo: transações	Bloqueio → 2ª via → vencimento	Zero execuções sem confirmação · zero duplicidade · reconciliação testada · aprovação de Risco

Valores iniciais, calibrados no shadow. A fase assistida antecipa valor e gera dados rotulados a cada edição.

7.2 Top 3 riscos arquiteturais

- 1. **Resposta errada com aparência de certa:** silenciosa, regulatória e reputacional. *Mitigação:* verificação de fundamentação, valores de fonte estruturada, documentos com dono e validade, avaliação da resposta final.
- 2. **Ação indevida pelo canal** (injection, engenharia social, falsa central). *Mitigação:* catálogo com negação por padrão, autenticação por risco, confirmação amarrada, política no executor, escrita fora do LLM, desbloqueio só no app.
- 3. **Dependência de integrações legadas:** a latência do legado vira latência da conversa. *Mitigação:* APIs levantadas na fase 0, MCP com idempotência e reconciliação, fila, degradação honesta, kill switch.

Monitorados: veto ao endpoint global (regional configurável), fim do preço promocional, descontinuação de modelo, guardrails em português, lock-in.

7.3 Desafios de adoção

Dono do conteúdo da base · ciclo de Risco, Compliance e Jurídico · adesão dos atendentes · prioridade dos times de sistemas legados · convivência com o time do atendimento atual · confiança do cliente e golpes · métrica de sucesso que não premie só contenção · soluções paralelas. Como enfrentar cada um: apêndice F.

Apêndice

A. Premissas e fontes de custo

Mix 50% conhecimento, 25% consulta, 15% transação, 10% fora de escopo · turnos 3/3/5/3 · tokens por chamada: classificador 1.500/100, resposta de conhecimento 6.000/800 (~500 de raciocínio, cobrado como saída), verificação 4.000/150 · Pro em 10% dos turnos de conhecimento. Custo de modelo por conversa (2026): conhecimento US\$ 0,042 · consulta 0,013 · fora de escopo 0,012 · transação 0,010 · média 0,027.

Componente	Valor usado	Fonte (26/set/2026)	Tipo
Gemini Flash	US\$ 0,75/3,75 por 1M até dez/2026; 1,50/7,50 depois	Preços de IA generativa, Google Cloud	Público
Gemini Pro	US\$ 1,25/10 por 1M	Idem	Público
Agent Runtime	US\$ 0,085/vCPU-h; 0,009/GiB-h (~US\$ 100/mês)	Preços da Agent Platform	Público × estimativa de uso
Banco vetorial	~US\$ 90/mês (100 unidades de processamento)	Preços do Spanner	Público × configuração
Model Armor	2M tokens/mês grátis; US\$ 0,10/1M (~US\$ 35/mês)	Preços do Security Command Center	Público
Serviços, dados, observabilidade	~US\$ 300/mês	—	Estimativa
Avaliações	~US\$ 200/mês	—	Estimativa
WhatsApp	Grátis quando iniciado pelo cliente	Política de preços da Meta	Oficial
Provedor de WhatsApp	US\$ 0,003–0,010 por mensagem	Referências de mercado	Não oficial

B. Sensibilidade

Premissa	Variação	Efeito no custo de modelo
Preço promocional → padrão	jan/2027	+92% (certo)
Turnos nas conversas de conhecimento	3 → 4	+26%
Uso do Pro	10% → 30%	+17%
Conhecimento no mix	+10 p.p.	+11% (consulta –7%, transação –7,5%, fora de escopo –6%)

C. Implantação

Componente	Onde roda	Região
Gateway de canal, política, servidores MCP	Cloud Run	São Paulo
Agente (um por área)	Agent Runtime (portável para Cloud Run)	São Paulo (verificado)
Conhecimento	RAG Engine	São Paulo (verificado)
Mascaramento	Sensitive Data Protection	São Paulo (endpoint regional)
Model Armor	Gerenciado	EUA (sem região no Brasil), sobre texto pseudonimizado
Cofre, registro de execuções, cache	Firestore (bancos separados)	São Paulo
Auditoria	BigQuery + armazenamento imutável	São Paulo
Modelos Gemini	Plataforma de IA	Global (sem identificadores nem dados financeiros)

Disponibilidade dos modelos e do Agent Runtime e RAG Engine verificada em chamadas reais em projeto GCP; Model Armor e Sensitive Data Protection, pela documentação oficial de regiões.

D. Integrações

A existência de cada API é premissa a confirmar no discovery.

Sistema	Finalidade	Via	Modo
Cartões	Listar, limite/fatura, bloquear, status, 2ª via, vencimento	Servidor MCP	Leitura e escrita, síncrono
Tarifas e produtos	Valores oficiais	Servidor MCP	Leitura, síncrono
CRM / atendimento	Histórico; protocolo e handoff	Servidor MCP	Leitura e escrita
Antifraude	Consulta prévia · aviso após bloqueio	MCP · barramento	Síncrono · assíncrono
WhatsApp, app	Mensagens	Gateway de canal	Síncrono

Sistema	Finalidade	Via	Modo
Provedor de identidade	Token, nível, step-up	Gateway de canal	Síncrono
Atendimento atual	Intenções não migradas	Gateway (roteador)	Síncrono
Notificação	Push por outro canal	Barramento	Assíncrono

E. Drift e degradação

Sinal	Ação
Mudança na distribuição de intenções	Alerta para negócio e segurança
Mais perguntas sem resposta	Backlog para os donos de conteúdo
Queda de qualidade	Investigação e rollback de versão
Aumento de custo ou latência	Revisão de roteamento e cache

F. Desafios de adoção

Desafio	Como enfrentar
Dono do conteúdo	Dono nomeado por documento, com validade; lacunas viram backlog
Risco, Compliance, Jurídico	Desde a fase 0; avaliações como evidência; relatório de impacto; residência decidida cedo
Atendentes	Fase assistida como copiloto; atendentes como avaliadores
Sistemas legados	Patrocínio executivo; APIs mínimas e reutilizáveis
Atendimento atual	Convivência; roteador com governança compartilhada; migração negociada
Clientes	Transparência; comunicação anti-golpe; valor percebido incentiva o vínculo pelo app
Métrica de sucesso	Recontato e CSAT pesam tanto quanto contenção
Soluções paralelas	Caminho oficial mais fácil; custos medidos como argumento

G. A confirmar no discovery

Mix e volume reais por motivo de contato · plataforma e interface do atendimento atual · APIs de cartões, tarifas, CRM e antifraude · jornada de autenticação existente no app e no WhatsApp · horário e ferramenta do atendimento humano · gateway de APIs corporativo · contrato com o provedor de WhatsApp · retenção de registros · posição de Compliance/DPO sobre o endpoint global.

H. Referências de implementação própria

Decisões deste documento aplicam métodos que usei em projetos próprios:

- [rag-quality-assurance](#): avaliação em níveis e o caso de recuperação perfeita com resposta errada.
- [finops-llm-routing](#): decisão de modelo por custo, com qualidade não negociável definida antes.
- [data-lake-engineering-decisions](#): registro de decisões e governança de dados para agentes.
- [amigurumi-agent](#): tracing de agente e humano no loop.
- [account-health-ml-service](#): drift e critério de produção definido antes.
- Em repositórios privados: template de servidor MCP com OAuth por usuário e agentes ADK em produção no GCP.